dataset-eval / data-test 预跑检测报告（第四轮 • 指针切换至 v2 • 2026-10-03）

> 工具：`tools/eval_test_audit.py`（纯标准库，只读；本轮新增 `--manifest`（活动清单）、`--source-dir`、`--train-dir` 与指针一致性检查 PTR001–PTR005）复现命令：`python tools/eval_test_audit.py --base data/v2 --manifest data/manifest.json --source-dir data/v2/sources --out dataset_audit_2026-10-03-eval-test-v4` 项目自带门禁（只读）：`data_check --manifest data/manifest.json`、`freeze_data --check`、`preflight --manifest … --strict/--ready`、`eval_test_prep status/check` 历史轮次：`…-eval-test`（NOT READY, hard 3）→ `…-v2`（hard 0, CONDITIONAL）→ `…-v3`（v1 复核 + v2 候选, hard 0）

---

0. 结论摘要与裁定

指针已切换生效：活动清单 `data/manifest.json`（6 条目）现引用 `v1/raw/*`（train）+ `v2/eval`、`v2/test`；`data/v1/manifest.json` 还原为 v1 归档；v2 双锁重冻并绑定活动清单。

维度	结果
检测基目录	`data/v2`（活动指针所指版本）
记录	eval 300（100 题×3 解）+ test 150 = **450**
逐条状态	**rejected 0 / quarantine 450 / clean 0**
我的检测	**hard 0**、quarantine **908**、info **858**（共 1766 条）
活动清单	6 条目，4 train + 1 eval + 1 test，**哈希 6/6 匹配**
冻结锁	`data/eval-v2.lock.json`、`data/test-v2.lock.json`，均绑定活动清单 `b11def7be9…`，条目哈希校验通过
隔离	精确重叠 0；≥0.7 近重复 **0**；最大 **0.6667**（未校准阈值）
镜像 `.json`↔JSONL	450/450 一致
行尾/哈希可复现	全 LF，通过
项目 `data_check`	**通过**（6 条目 / 问题 0 / quarantine 0）
项目 `freeze_gate`	**PASS**（冻结证据绑定当前 manifest，eval/test 全量覆盖）
项目 `preflight --ready`	**NOT READY**（5 项阻断，见 §5）

裁定

- **数据结构与指针层面：通过。**指针漂移没有留下悬空引用（活动清单哈希 6/6 匹配、v2 双锁校验"冻结完好"、`data_check` 0 问题）。
- **仍不可引用为训练/评测数据**：项目自带 `preflight --ready` 判定 **NOT READY**，阻断项为 `near_dup_calibrated`（近重复阈值 UNCALIBRATED）、`asset_evidence`（无资产验收证据 = 动画未经真实渲染/数学验收）、`exec_isolation`（网络隔离未实施），以及本次探针未提供的 `model_dir`、`run_snapshot`。
- **本轮新增待处理 4 项**：`A005`×4（v2 有 4 条 steps 未以"第N步"开头）、`PTR005`（`eval_test_prep.py` 默认指针仍为 `data/v1`）、`D012`×3（文档仍写"未冻结"）、`PTR003`/`PTR004`（活动清单 name/generated_at 未随切换刷新，info）。

1. 范围、快照与只读保证

类别	本轮对象
活动指针	`data/manifest.json`（2525 B，23:52:48）
入口 JSONL	`data/v2/eval/dataset_eval.jsonl` (433369, 23:24:31)、`data/v2/test/dataset_test.jsonl` (200390, 23:24:31)
镜像 JSON	`data/v2/eval/dataset_eval.json` (483800)、`data/v2/test/dataset_test.json` (223709)
源手稿	`data/v2/sources/dataset-eval.md` (205684)、`data/v2/sources/data-test.md` (118713)
子清单	`data/v2/eval/manifest.json`、`data/v2/test/manifest.json`（各 573 B）
冻结锁	`data/eval-v2.lock.json`、`data/test-v2.lock.json`
训练参考池	`data/v1/raw/dataset_{calc,geom,linalg,prob}.jsonl`（63 条，LF）
归档（不再活动）	`data/v1/manifest.json`、`data/v1/manifest-train.json`、`data/v1/{eval,test}/*`、`data/{eval,test}-v1.lock.json`

- 检测快照：`2026-10-03T16:05:44Z`（= 北京时间 00:05）；18 个受检文件在检测后立即复核，哈希无变化。
- **环境说明（重要）**：项目 `.venv` 的解释器位于工作区外（`D:\Python\python.exe`）。在我的沙箱（workspace-write）下该路径被拒绝访问，`python` 回退到系统解释器 3.14.7（无 manim/sympy/markdown_it）——这会让 `preflight` 的 `render_gate` / `math_gate` 出现**假 FAIL**。改用项目 venv（一次性放宽权限）后两项均 **PASS**，故 §5 采用 venv 下的权威结论。venv 本身**并未损坏**。
- 只读保证：未修改任何数据、文档、清单或锁；未自动改 ID/公式；未启动训练、未下载模型、未生成动画。

2. 原始文件哈希（SHA256，本轮快照）

文件	字节	SHA256（前 12 位）
`data/manifest.json`（活动）	2525	`b11def7be902`
`data/v2/eval/dataset_eval.jsonl`	433369	`8f18123fcb3f`
`data/v2/test/dataset_test.jsonl`	200390	`d4de0bb6a86f`
`data/v2/eval/dataset_eval.json` / `test…json`	483800 / 223709	`1de2df62edd0` / `15a524ceeb1b`
`data/v2/eval/manifest.json` / `test/manifest.json`	573 / 573	`8830f1d266d4` / `cd681f55f7d4`
`data/eval-v2.lock.json` / `test-v2.lock.json`	469 / 469	`1a84b5b3c723` / `24c55a096fd1`
`data/v2/sources/dataset-eval.md` / `data-test.md`	205684 / 118713	`d681996dcf54` / `d36cab40f199`
`data/v1/raw/dataset_{calc,geom,linalg,prob}.jsonl`	32908 / 18138 / 31002 / 15462	`9f862c7c6876` / `bbd5c6ad09e9` / `f83723a082b0` / `5ddd3a1c25b9`
`data/v1/{eval,test}/README.md`	282 / 258	`31012b92e42e` / `80bb3754595a`
`.gitattributes`	92	`a2dc85e2442c`

> 完整清单见 `file_hashes.json` / `file_hashes.sha256`（18 个文件）。

---

3. 指针一致性检查

检查	结果
`PTR002` 活动清单是否覆盖本轮基目录	**通过**（清单含 `v2/eval`、`v2/test`）
活动清单条目哈希 vs 文件	**6/6 匹配**（train 4 + eval + test）
锁 ↔ 活动清单绑定	**通过**：两把 v2 锁 `manifest_sha256 = b11def7be9…` 与活动清单一致；`freeze_data --check` 均报"冻结完好"
`PTR003` 清单 name	info：`animation-data-v1` 仍含 v1 字样，而 eval/test 已指向 v2
`PTR004` 清单 generated_at	info：`2026-10-03 18:42:00` 早于其指向文件最新 mtime `23:24:31`（时间戳未随重写刷新）
`PTR005` 工具默认指针	**quarantine**：`tools/eval_test_prep.py` 默认 `--dir` 仍为 `data/v1`。实测 `status` 报"eval-v1 锁校验通过、eval-v2 锁覆盖其他版本文件,不参与本次判定"——**不带参数运行时会判定归档版本**，与活动指针相反

> 说明：`data/v1/manifest.json` 归档化本身正常（提交 `68c51be` 声明"data/v1/manifest.json 还原为 v1 归档"）；问题只在**工具默认参数**未随指针切换。

---

4. 独立检测结果（基目录 data/v2 + 活动清单）

- **hard 0**、quarantine 908、info 858（共 1766 条）。
- 结构/字段/身份/多解组/镜像/LaTeX/隔离/冻结/清单登记：全部通过（逐项见 §6）。
- 逐条状态：450 条全部 `quarantine`（无 rejected、无 clean）——quarantine 来自系统级项（许可证待转正、动画未验证）与少量新发现问题。

4.1 本轮新增发现

代码	条数	内容
`A005`	**4**	v2 有 4 条记录的 `steps` 未以"第N步"开头（`eval-calc-023-s1/s2/s3`、`eval-prob-010-s2`）——v2 逐解法重写时的格式不一致
`PTR005`	1	`eval_test_prep.py` 默认指针仍为 `data/v1`（见 §3）
`PTR003` / `PTR004`	各 1	活动清单 name / generated_at 未随切换刷新（info）

4.2 与第三轮相比的变化（v2 数据在 23:24 又改过一次）

- `data/v2/eval/dataset_eval.jsonl` 432636 → **433369 B**（objects 612 → 617，L007 100 → 101），新增 `A005` ×4；

- `eval-linalg-023-s3` 已按复查意见修正：现明确区分"形式一（完整实不可约分解）"与"形式二（合并书写,尚未完全分解）"，并给出连接恒等式证明——**Lead 复核正确**；
- 其余结构与隔离结论不变。

4.3 仍未关闭（跨轮）

代码	条数	内容
`P002`	450	`license=Internal-Research-Use-Only`（仅内部研究、不公开分发），训练/公开前须转正
`A008`	450	动画未验证（无 `code` / `render_status` / `code_sha256`），scene_spec 仍是设计稿
`D012`	3	`EVAL_TEST_PREP.md` 与 `data/v1/{eval,test}/README.md` 仍写"未冻结"

---

5. 项目自带门禁（在项目 venv 下运行，权威结论）

门禁	结果	说明
`data_check --manifest data/manifest.json`	**通过**	6 条目 / 问题 0 / quarantine 0
`freeze_data --check data/{eval,test}-v2.lock.json`	**冻结完好** ×2	锁结构与文件哈希一致
`preflight --strict` → gpu	PASS	RTX 5060 Laptop 8151 MiB
→ data_manifest	PASS	6 条目,问题 0
→ render_gate	PASS	固定 smoke 渲染成功（**非资产验收证据**）
→ math_gate	PASS	固定数学 smoke 断言成立（**非资产验收证据**）
→ freeze_gate	**PASS**	冻结证据绑定当前 manifest，eval/test 全量覆盖
→ model_dir	FAIL	本次探针未提供 `--model`（非数据缺陷）
→ run_snapshot	FAIL	本次无 `runs/<id>/run_record.json`（非数据缺陷）
→ near_dup_calibrated	**FAIL**	近重复阈值仍 UNCALIBRATED（真实数据对照实验未完成）
→ asset_evidence	**FAIL**	`asset_evidence.json` 不存在：资产未经真实渲染/数学验收 → UNVERIFIED
→ exec_isolation	**FAIL**	网络隔离未实施（现有：cwd 隔离+环境脱敏+禁 shell+超时+内存上限）
`preflight --ready`	**NOT READY**	阻断：`model_dir`、`run_snapshot`、`near_dup_calibrated`、`asset_evidence`、`exec_isolation`

> `render_gate` / `math_gate` 在系统 Python 下会假 FAIL（缺 manim/sympy），在项目 venv 下为 PASS——**不要**把沙箱/解释器差异当成数据缺陷。

---

6. 逐项检查结果

检查	结果
JSONL 结构（解析/空行/BOM/重复键）	通过（0 异常）

检查	结果
字段与类型（id 唯一、12/15 字段、无未知字段）	通过
身份唯一性（eval 300 + test 150，跨池无交集）	通过
同题多解组（100 组×3 解、题干一致、method 唯一）	通过
同题多解场景互异（`G003`）	通过（0 组完全相同）
LaTeX（公式内 CJK/全角/`$`/括号）	通过（0 硬性缺陷；`L006` ×11、`L009` ×7 经复核为误报降级 info）
scene_spec 结构	通过（450/450 含 objects+steps；`A005` ×4 为步骤前缀格式，见 §4.1）
镜像 `.json` ↔ JSONL	通过（450/450）
源手稿 ↔ 交付身份覆盖	通过（100/100、150/150）
与 train 隔离	通过（精确 0；max 0.5915）
eval ↔ test 隔离	通过（精确 0；max 0.6667；≥0.7 对数 0）
活动清单登记	通过（6/6 哈希匹配）
冻结锁	通过（绑定活动清单，条目校验通过）
文档状态	不通过（`D012` ×3：仍写"未冻结"）
动画验证	不通过（0/450）
许可证	不通过（450/450 内部研究许可）

7. quarantine 清单（908 条）

代码	条数	处置
`P002`	450	用户级：许可证转正（训练/公开前）
`A008`	450	用户级：过 `render_gate` 并登记 `code` / `render_status` / `code_sha256`
`A005`	4	**工程级（本轮新增）**：统一 v2 steps 的"第N步"前缀
`D012`	3	文档：更新 `EVAL_TEST_PREP.md` 与两个 v1 README 的冻结状态
`PTR005`	1	**指针（本轮新增）**：把 `eval_test_prep.py` 默认基目录切到活动版本

8. info 亮点（858 条）

代码	条数	内容
`P003`	450	`source=self-authored`（如实）
`C007`	274	answer 与 solution 无文本重合（纯文字结论，正常）
`L007`	101	双上下标（合法）
`L006` / `L009`	11 / 7	`\leftarrow`、`\dfrac12` 误报（已复核为合法）
`X002`	3	三对池最大近重复（0.5915 / 0.3895 / 0.6667）
`PTR003` / `PTR004`	各 1	活动清单 name / generated_at 未刷新
`LK007` / `LK008`	2 / 1	本版本锁校验通过 / 他版本锁未参与校验

代码	条数	内容
`G002` / `G003`	各 1	多解组 {3:100} / 场景互异通过
`MF008`	1	train 标签为"用户拍板 provisional"（如实）
`R001`	1	既有内容评审 64 条（A5/B31/C28）纳入交叉核对

9. 汇总统计

项	eval	test
记录 / 唯一身份	300 / 300	150 / 150
题目数	100（每组 3 解）	150
子类数	41	144
objects / steps	617 / 1212	303 / 603
method 数	263	—
状态	quarantine 300	quarantine 150

- 板块：eval（高代 105 / 数分 90 / 几何 60 / 概率 45，按解法计）；test（数分 45 / 高代 40 / 几何 25 / 概率 25 / 跨学科 15）。
- 严重度：hard 0、quarantine 908、info 858（共 1766）。
- 隔离：精确重叠 0；≥0.7 近重复 0；最大 0.6667（阈值 UNCALIBRATED）。

10. 裁定与建议

指针切换本身成功：活动清单、锁、哈希、`data_check`、`freeze_gate` 全部一致，独立性（train/eval/test 隔离）保持通过。

引用前需完成（按优先级）：

1. **工程级收尾（本轮新增，易修）**：① `A005` ×4 统一 steps 前缀；② `PTR005` 把 `eval_test_prep.py` 默认基目录切到活动版本（否则默认运行会判定归档 v1）；③ `PTR003` / `PTR004` 刷新活动清单 name 与 generated_at；④ `D012` 更新文档冻结状态。
2. **项目级门禁（`preflight --ready` 阻断项）**：`near_dup_calibrated`（完成 0.7 阈值校准，本轮边界对 0.6667 可作样本）、`asset_evidence`（生成真实渲染/数学验收证据，替代环境 smoke）、`exec_isolation`（网络隔离）；`model_dir` / `run_snapshot` 在正式 `--ready` 需一并提供。
3. **用户级决策**：`P002` 许可证转正；`A008` 动画验证（450 条 scene_spec 仍为设计稿，v2 的逐解法重写尚未过 `render_gate`）。

结论：指针指向 v2 后，数据与清单/锁层面**已自洽**（hard 0、`data_check` 通过、`freeze_gate` PASS），但**整体仍为 NOT READY**——阻断来自"阈值未校准 + 无资产验收证据 + 无网络隔离 + 无模型/运行快照"，而非数据本身。

11. 产物清单

路径	内容
`dataset_audit_2026-10-03-eval-test-v4/AUDIT_REPORT.md` / `.pdf`	本报告
`dataset_audit_2026-10-03-eval-test-v4/issues.jsonl`	逐条问题（1766 条）
`dataset_audit_2026-10-03-eval-test-v4/record_status.jsonl` / `.csv`	450 条逐条状态
`dataset_audit_2026-10-03-eval-test-v4/summary.json`	汇总（含 pointer / locks / isolation / per_split）
`dataset_audit_2026-10-03-eval-test-v4/file_hashes.json` / `.sha256`	18 个受检文件哈希
`tools/eval_test_audit.py`	只读检测工具（支持 `--base` / `--manifest` / `--source-dir` / `--train-dir`）

声明：本轮为只读检测，未修改任何数据、文档、清单或锁；未自动改 ID/公式；未启动训练、未下载模型、未生成动画。