三方底座模型对照报告(MODEL_COMPARISON)

> 生成时间:2026-10-03 15:26:27。任务:problem+solution → scene_spec 结构化 JSON(20 条子类分层样本,输入哈希冻结)。仅筛选测量,不构成正式训练;candidate/UNVERIFIED 语义保持。

1. 推理对照(20 条,同口径冻结 seed/GenerationConfig)

模型/模式	严格 JSON 解析率	宽松提取率	4bit 加载显存	热延迟/条	总生成 token
qwen2.5-7b	35%	35%	5.97 GB	9.8 s	4261
qwen3-4b	50%	50%	2.89 GB	20.6 s	6678
qwen3-4b-thinking	80%	80%	2.89 GB	44.3 s	14275
qwen3-8b	65%	65%	6.49 GB	18.6 s	6085
qwen3-8b-thinking	65%	65%	6.49 GB	44.1 s	15317

2. QLoRA 训练资源探针(seq=1024 精确 token,3 步)

模型	训练峰值 allocated	训练峰值 reserved	平均步时	失败步	adapter 体积
qwen2.5-7b	8.33 GB	9.40 GB	[3.83, 2.87, 2.86]	0	20221148
qwen3-4b	5.33 GB	6.42 GB	[2.74, 2.36, 2.37]	0	23637595
qwen3-8b	9.02 GB	10.12 GB	[6.06, 6.53, 6.52]	0	30715547

3. 未测维度(NOT_MEASURED,如实)

- FP16-vs-4bit 退化对照:未测
- TTFT 细分:未测
- 梯度累积吞吐:未测
- 断点恢复验证:未测(adapter save ≠ 恢复验证)
- 数学/内容人工复核:未测(仅规则可解析率)
- seq_len 曲线全档(2048/4096):未测
- Windows+bnb 兼容性:已实测通过(三模型 4bit 加载均成功)

4. 环境与证据

- GPU: NVIDIA GeForce RTX 5060 Laptop(8GB),torch 2.11.0+cu128;
- 每 run 目录含逐样本完整输出/哈希/命令/env/provenance 哈希;
- 原始 run 数据留存于 outputs/screening-tmp/,撤组前归档。

5. 结论建议(待用户拍板)

- 数据为 provisional train 筛选成绩,不当正式 eval/test 验收;
- baseline 选择需综合解析率、显存余量、延迟与训练可行性,由用户决定。