dataset-eval / data-test 预跑检测报告（第二轮 • 2026-10-03）

> 工具：`tools/eval_test_audit.py`（纯标准库，只读；复用 `tools/dataset_audit.py` 的结构/一致性/LaTeX/scene_spec/来源许可证规则，并新增冻结锁校验、manifest 条目契约、EOL 哈希绑定、元数据卫生检查） 复现命令： `python tools/eval_test_audit.py --out dataset_audit_2026-10-03-eval-test-v2` 项目自带预检（只读）：`python tools/eval_test_prep.py check --eval data/v1/eval --test data/v1/test --train-dir data/v1/raw` → **exit 0** 契约依据：`DATASET_SCHEMA.md`、`EVAL_TEST_PREP.md`；证据：`issues.jsonl`、`summary.json`、`record_status.jsonl/.csv`、`file_hashes.*` 上一轮（第一轮）：`dataset_audit_2026-10-03-eval-test/`（裁定 NOT READY，hard 3）

0. 结论摘要与裁定

维度	本轮（第二轮）	上一轮
样本总量	**450 条**（eval 300 = 100 题×3 解；test 150）	同
逐条状态	**rejected 0 / quarantine 450 / clean 0**	rejected 3 / quarantine 447
问题计数	**hard 0**、quarantine 1364、info 833（共 2197）	hard 3、quarantine 2267、info 829
结构 / 字段 / 类型	通过	通过
身份唯一性	通过（eval 300 唯一 id + 100 组多解；test 150 唯一）	eval 无 id
同题多解组约束	通过（100 组×恰 3 解）	通过
LaTeX 硬性缺陷	0（公式内 CJK/全角全量扫描命中 0）	0
与 train 隔离	**通过**：精确重叠 0；最大近重复 **0.5915** < 0.7	通过
eval ↔ test 隔离	**通过**：精确重叠 0；最大近重复 **0.6667** < 0.7；≥阈值对数 **0**	**不通过**（0.7619，3 条）
manifest 登记	通过（根 manifest 6 条，含 eval/test）	未登记
冻结锁	**已建立**（2 个锁，绑定根 manifest，条目哈希校验通过）	无锁
元数据完备性	513/513 齐全（eval/test/train 全部补齐）	450/450 缺
文档与数据一致	仅剩"未冻结"字样滞后	多处不符

裁定：硬门禁通过（CONDITIONAL PASS）——可进入用户裁定/补齐阶段，但仍不能直接投入训练或评测

- 上一轮的 **3 项 hard 全部清零**：跨池近重复题已拆题、eval 已补全局唯一 id、manifest 已顶层登记，隔离与冻结两项硬门禁成立。
- 仍有 **6 类 quarantine（1364 条）**，其中 **4 项建议投用前必须处理**（§9）：哈希/EOL 不可复现（5）、manifest 条目契约（4）、元数据批量残留（450）、文档状态滞后（5）；另 2 项为已知的用户级决策（动画未验证 450、许可证待转正 450）。

1. 检测范围、快照与只读保证

类别	文件（本轮快照时间按文件 mtime）
正式入口（检测对象）	`data/v1/eval/dataset_eval.jsonl` (18:53:57)、`data/v1/test/dataset_test.jsonl` (18:53:57)
镜像容器	`data/v1/eval/dataset_eval.json` 、`data/v1/test/dataset_test.json`
来源手稿	`dataset-eval.md` (18:42:58)、`data-test.md` (18:42:58)
训练参考池（隔离基准）	`data/v1/raw/dataset_{calc,geom,linalg,prob}.jsonl` （63 条，01:23–01:57）
清单	`data/v1/manifest.json` (18:54:32)、`manifest-train.json` (18:53:57)、`data/v1/{eval,test}/manifest.json` (18:54:32)
冻结锁	`data/eval-v1.lock.json` 、`data/test-v1.lock.json` (18:59:05)
规则文件	`.gitattributes` (18:41:33)

> **并发说明**：本轮开始时锁文件位于 `data/v1/{eval,test}/dataset_*.lock.json` ，检测过程中（18:59:05）被移动到 `data/{eval,test}-v1.lock.json` ； 随后 19:01:57 根清单 `data/v1/manifest.json` 被重生成（eval/test 条目的备注由"未冻结"改为"已冻结(data/{eval,test}-v1.lock.json 绑定本清单)"） ，两个锁同步重绑到新清单哈希 `636d4902…` 。**本报告以 19:03:35 的最终快照为准**，全部哈希见 `file_hashes.json` 。 **文件名说明**： `dataset-test.md` 在仓库中的实际文件名为 `data-test.md` 。 只读保证：未修改任何数据/文档/manifest/锁；未自动改 ID 或公式；未启动训练、未下载模型、未生成动画。

---

2. 原始文件哈希（SHA256，本轮快照）

文件	字节	mtime	SHA256（前 12 位）
`data/v1/eval/dataset_eval.jsonl`	465152	18:53:57	`9e5b7355606d`
`data/v1/test/dataset_test.jsonl`	201290	18:53:57	`e1ba1eb49dd7`
`data/v1/eval/dataset_eval.json`	524255	18:53:57	`f75bcf5dabe1`
`data/v1/test/dataset_test.json`	224609	18:53:57	`0e02da48040b`
`dataset-eval.md` / `data-test.md`	182347 / 118654	18:42:58	`6fd913bc89d8` / `342e6d0e4d49`
`data/v1/manifest.json`	2635	19:01:57	`636d4902d001`
`data/v1/manifest-train.json`	2105	18:53:57	`eb630bc1dc3d`
`data/v1/eval/manifest.json` / `test/manifest.json`	1226 / 1226	18:54:32	`cef290f0e32f` / `6a6604d1ce74`
`data/eval-v1.lock.json` / `data/test-v1.lock.json`	485 / 485	19:01:57	`a3f1c17ca6a6` / `c2394c7b4735`
`data/v1/raw/dataset_{calc,geom,linalg,prob}.jsonl`	32927 / 18150 / 31025 / 15471	01:23 / 01:23 / 01:57 / 01:57	`65d9c9255cd6` / `109d993d8dfd` / `2fa2a95de269` / `254626ccd2f1`
`.gitattributes`	92	18:41:33	`a2dc85e2442c`

> 共 19 个受检文件，完整哈希见 `file_hashes.json` / `file_hashes.sha256`。**最终快照时间 19:03:35**；检测跑完后立即复核，19 个文件全部未再变动。

---

3. 与第一轮（NOT READY）的差异

3.1 上一轮 3 项 hard：全部清零

上一轮 hard	本轮状态	证据
`eval-linalg-006`（×3 解）↔ `test-linalg-003` 近重复 0.7619	**已修复**	`test-linalg-003` 已换题（现为"求所有满足 $B^2=A$ 的二阶实矩阵"，Lead 手算 $B=\pm\begin{pmatrix}1&1\0&1\end{pmatrix}$，$B^2=A$ 且由与 A 交换 + $p^2=s^2=1,q(p+s)=2$ 证唯一）；与该题相似度降至阈值以下
eval 无 `id`，与 `DATASET_SCHEMA §2`「id 缺失 = 硬伤」冲突	**已修复**	eval 300 条均有唯一 `id`（`eval-calc-001-s1` … `eval-linalg-035-s3`），与 test/train 无交集
eval/test 未被 manifest 登记、无冻结锁	**已修复**	根 manifest 6 条（train×4 + eval + test）；锁 2 个并绑定根 manifest 哈希

3.2 上一轮 quarantine：已清除 10 类

- `F010` 可选元数据缺/空 **1350 → 0**（eval 300 + test 150 + train 63 全部补齐 function_family / visual_style / efficiency_tags）；
- `S002` CRLF 行尾 **2 → 0**（eval/test JSONL 已 LF 化，`.gitattributes` 声明 `*.jsonl/*.json eol=lf`）；
- `MF006` 未登记 **2 → 0**、`MF007` 无冻结锁 **2 → 0**、`MF004` manifest 哈希不符 **0**；
- `G001` 契约分歧 **1 → 0**（eval 有 id）；`D004` / `D005` / `D010` 文档"未生成/未转 JSON"字样已更新；
- 根清单**（检测期间修复）** 19:01:57 重生成：eval/test 条目备注由"未冻结"改为"已冻结(…lock.json 绑定本清单)"，两个锁同步重绑到 `636d4902…`，锁校验仍通过；
- 镜像一致性保持（eval 300/300、test 150/150 与 JSONL 逐条相同）。

3.3 本轮新增发现（上一轮不存在或未检出）

代码	条数	内容
`F011`	450	efficiency_tags 条目残留 Markdown 项目符号 `"- "`（批量写入残留）
`W001`	5	记录哈希绑定 CRLF，而 `.gitattributes` 声明 `eol=lf` → 全新 clone 后校验失败
`MF005`	2	同一文件在根 manifest（`eval` / `test`）与分目录 manifest（`raw`）中 split 取值冲突
`MF009`	2	分目录 manifest 把 JSON 数组容器 `dataset_{eval,test}.json` 登记为数据条目
`D011`	2	两份手稿仍称"未冻结"，但相应冻结锁已建立
`D012`	3	`EVAL_TEST_PREP.md` 与两个 README 仍写"未冻结"
`MF010`	2	分目录 manifest 把 `README.md` 登记为数据条目（info）

---

4. 硬门禁逐项结果

#	门禁	结果
G1	JSONL 结构（解析/空行/BOM/重复键）	**通过**（0 异常）
G2	必需字段、类型、未知字段	**通过**（0 缺、0 类型错、0 未知字段）
G3	身份唯一性	**通过**（eval 300、test 150；跨池无交集）
G4	同题多解组约束	**通过**（100 组，每组恰 3 解，题干一致、method 唯一）
G5	answer 可判分性	通过
G6	LaTeX（公式内 CJK/全角/`$`/括号）	**通过**（0 硬性缺陷）
G7	scene_spec 结构	**通过**（450/450 含 objects+steps）
G8	镜像一致性	**通过**（450/450 逐条相同）
G9	与 train 隔离	**通过**（精确 0；max 0.5915）
G10	eval↔test 隔离	**通过**（精确 0；max 0.6667；≥0.7 对数 0）
G11	manifest 登记	**通过**（根 manifest 含 eval/test）
G12	冻结锁与哈希绑定	**通过**（2 锁，均绑定 `data/v1/manifest.json` `6ce669f2…`；条目哈希/大小校验通过）
G13	元数据完备性	**通过**（513/513）
G14	文档与数据一致	不通过（"未冻结"字样滞后，5 条）
G15	哈希可复现性	不通过（`W001` ×5）
G16	manifest 条目/拆分语义	不通过（`MF005` ×2、`MF009` ×2）
G17	动画验证	不通过（0/450，scene_spec 仍为设计稿）
G18	许可证	不通过（450/450 `Internal-Research-Use-Only`，训练/公开前须转正）

---

5. 隔离检测

池对	精确重叠	最大 5-gram Jaccard（set）	≥0.7 对数
train ↔ eval	0	0.5915（`linalg-067` vs `eval-linalg-007-s1`）	0
train ↔ test	0	0.3895（`linalg-067` vs `test-linalg-021`）	0
eval ↔ test	0	**0.6667**（`eval-calc-023-s1` vs `test-calc-013`）	**0**

- 三对均低于未校准阈值 0.7，隔离判定通过；跨池 ID 交集为空。

- **边界对研判（Lead 复核）**：`eval-calc-023-s1`「证明级数 $\sum 1/n^2$ 收敛」与 `test-calc-013`「求级数 $\sum 1/(n(n+2))$ 的和」——级数不同、任务不同（证明收敛 vs 求和），0.6667 主要来自共用 LaTeX 脚手架，**属结构性相似而非题面泄漏**；但距阈值仅 0.033，建议纳入阈值校准样本。
- **门禁盲区仍未补**：`tools/eval_test_prep.py check` 的 eval↔test 比较仍只用"核心正文哈希 + ID"（`_group_sets`），**未做组间近重复**。本轮 0 泄漏是数据层面的结论，若后续新增题目，该门禁不会拦住 eval↔test 的近似题。上一轮已提出，本轮仍未关闭。

---

6. 逐项检查结果

6.1 结构与字段

4 个入口/镜像文件全部可解析；0 空行、0 重复键、0 BOM；eval 15 字段（比上一轮多 `id` + 3 项元数据）、test 12 字段；无未知字段。

6.2 身份与同题多解

eval：300 条 = 100 个 problem_id × 恰 3 解；`id` 全局唯一（`eval-*-NNN-sM`），`solution_id` 唯一，method 名共 263 个；同组题干一致。test：150 条 `test-*-NNN`（含跨学科 `test-x-*`）唯一。train：63 条不变。三池 ID 两两无交集。

6.3 手稿↔交付

`dataset-eval.md` 100 个题号 ↔ eval 100 个 problem_id 完全对应；`data-test.md` 150 个题号 ↔ test 150 个 id 完全对应；规模声明（100/150 题）与实际一致。

6.4 LaTeX

全量扫描 450 条 problem/solution/answer 与 scene_spec 的 `$...$` 片段：**公式内中文/全角命中 0**。7 条 `\leftarrow` 误报（`\left` 规则需字母边界）、3 条 `\frac32`（合法单 token）、1 条 `A^2=A` 恒等演示（C008）经复核为误报，均已降为 info。

6.5 scene_spec 与动画

450/450 含非空 objects（1203）与 steps（1503），步骤编号连续；**动画验证 0/450**（无 code/render_status/code_sha256）→ 状态只能是 candidate/UNVERIFIED。

6.6 来源与许可证

450/450 `source=self-authored`、`license=Internal-Research-Use-Only`；该许可仅限内部研究、不公开分发，训练/公开前必须转正（与 train 池一致）。

6.7 manifest 与冻结

- 根 `manifest.json`：6 条（train×4、eval、test），4/4 train 条目标 `train` 且 notes 注明"用户拍板 provisional：candidate 未验收、动画未验证"。
- `manifest-train.json`：4 条（同哈希、同 split），notes 同样注明 provisional → **如实**（本轮降为 info）。
- `data/v1/{eval,test}/manifest.json`：各 3 条，**split 全为** `raw`，且把 `.json` 数组容器与 `README.md` 登记为数据条目 → 语义/条目契约问题（§7）。
- 冻结锁：`data/eval-v1.lock.json`、`data/test-v1.lock.json`，均 `locked=true`、绑定根 manifest `6ce669f2…`、条目哈希与大小校验通过 → **冻结有效**。

6.8 文档状态

`EVAL_TEST_PREP.md`、`data/v1/{eval,test}/README.md`、`dataset-eval.md`、`data-test.md` 仍含"未冻结"字样，而锁已于 18:59 建立 → 5 条 quarantine。

---

7. 逐条问题清单

7.1 硬伤：0 条

7.2 quarantine（1364 条，按代码）

代码	条数	内容	级别
`A008`	450	动画未验证（scene_spec 无 code/render_status/code_sha256）	已知，需 render_gate
`P002`	450	`license=Internal-Research-Use-Only`，训练/公开前须转正	已知，用户级
`F011`	450	efficiency_tags 首条残留 `"- "` 项目符号（批量写入残留）	建议清理
`W001`	5	记录哈希绑定 CRLF 而 `.gitattributes` 声明 `eol=lf`：4 个 raw JSONL + 根 manifest.json → 全新 clone 后校验失败	**建议投用前修**
`D012`	3	`EVAL_TEST_PREP.md`、两个 README 仍写"未冻结"	文档滞后
`MF005`	2	`dataset_eval/test.jsonl` 在根 manifest 标 `eval` / `test`、在分目录 manifest 标 `raw`	**建议投用前修**
`MF009`	2	分目录 manifest 把 `.json` 数组容器登记为数据条目（`DATASET_SCHEMA §1`）	**建议投用前修**
`D011`	2	两份手稿仍称"未冻结"	文档滞后

7.3 info（833 条，按代码）

代码	条数	内容
`P003`	450	`source=self-authored`（如实）
`C007`	274	answer 与 solution 无文本重合（纯文字结论，正常）
`L007`	86	双上下标（`x_1^2`，合法）
`L006`	7	`\leftarrow` 经复核为误报
`L009`	3	`\frac32` 合法单 token
`X002`	3	三对池的最大近重复（0.5915 / 0.3895 / 0.6667）
`M002`	2	`.json` 仅作镜像（入场工具只选 `*.jsonl`）
`MF010`	2	分目录 manifest 登记 README
`LK007`	2	冻结锁校验通过（绑定根 manifest）
`C008`	1	`A^2=A` 恒等演示经复核为误报
`G002`	1	eval 多解组 100 组、解法数分布 {3: 100}
`MF008`	1	train 标签为"用户拍板 provisional"，notes 已注明未验收（如实）

代码	条数	内容
`R001`	1	既有内容评审 64 条（A5/B31/C28）已纳入交叉核对

---

8. 汇总统计

项	eval	test	合计
记录数	300	150	**450**
唯一身份	300	150	450
题目数	100（每题 3 解）	150	250
子类数	41	144	—
objects / steps	1200 / 1500	303 / 603	1503 / 2103
状态	quarantine 300	quarantine 150	**rejected 0 / quarantine 450 / clean 0**
动画验证	0	0	**0**

- 板块：eval（高代 105 / 数分 90 / 几何 60 / 概率 45，按解法计）；test（数分 45 / 高代 40 / 几何 25 / 概率 25 / 跨学科 15）。
- 严重度：hard 0、quarantine 1364、info 833（共 2197 条）。
- 隔离：精确重叠 0；≥0.7 近重复 0；最大 0.6667。
- 冻结：2 锁、绑定根 manifest、条目校验通过。

---

9. 裁定与建议

判定：硬门禁通过；投用前仍需清 4 项 + 2 项用户级决策

必须处理（本轮新增，建议优先）：

1. `W001` **（5）哈希可复现性**：raw 4 个 JSONL 与根 `manifest.json` 的记录哈希基于 CRLF，而 `.gitattributes` 声明 `*.jsonl/*.json eol=lf` → 全新 clone 得到 LF 文件后 sha256 变化，`data_check`/冻结锁校验会失败。建议：把落盘改为 LF 后重算并重冻，或对这些文件声明 `-text` 固定字节（eval/test 已是 LF，可作为参照）。
2. `MF005` + `MF009` **（4）manifest 条目与拆分语义**：分目录 manifest 把 eval/test 标成 `raw`、并把 `.json` 数组容器登记为数据条目；建议修正 split 或删除重复清单，只保留根 manifest 作为唯一权威。
3. `F011` **（450）元数据残留**：efficiency_tags 首条以 `"- "` 开头（Markdown 项目符号混入数据），建议清理。
4. `D011` + `D012` **（5）文档状态**：`EVAL_TEST_PREP.md`、两个 README、两份手稿仍写"未冻结"，与 18:59 的冻结事实不符。

用户级决策（已知，非本轮新增）： 5. **动画验证 0/450**：scene_spec 仍为设计稿；进入训练/评测前需过 `render_gate` 并登记 `code/render_status=verified` / `code_sha256`。 6. **许可证**：450/450 为 `Internal-Research-Use-Only`，训练与公开前须转正。

另建议（门禁能力，非数据缺陷）： 7. 给 `tools/eval_test_prep.py check` 补 **eval↔test 近重复比较**（当前只用精确哈希+ID）；并把 5-gram 阈值 0.7 做一次校准（本轮边界对 0.6667 已被判定为结构性相似，可作为校准样本）。

结论：本轮相比上一轮的 NOT READY 有实质进展——**隔离、冻结、登记、元数据四项硬门禁全部成立，hard 归零**；剩 4 项属于可机械修复的工程/卫生问题 + 2 项用户级决策。清理完第 1–4 项后，可再次预跑复核并进入冻结批准流程。

10. 产物清单

文件	内容
`AUDIT_REPORT.md` / `AUDIT_REPORT.pdf`	本报告
`issues.jsonl`	逐条问题（2197 条）
`record_status.jsonl` / `.csv`	450 条逐条状态
`summary.json`	汇总统计（含隔离矩阵、冻结锁、镜像一致性、既有评审计数）
`file_hashes.json` / `.sha256`	19 个受检文件哈希
`tools/eval_test_audit.py`	本轮只读检测工具（可复现）

声明：本轮为只读预跑检测，未修改任何数据、文档、manifest 或锁；未自动改 ID/公式；未启动训练、未下载模型、未生成动画。