dataset-eval / data-test 预跑检测报告（第三轮 • 2026-10-03）

> 工具：`tools/eval_test_audit.py`（纯标准库，只读；本轮新增 `--base` 支持对 v1/v2 两版候选分别检测，并新增同题多解场景互异性、基目录清单/锁归属检查） 复现命令： `python tools/eval_test_audit.py --base data/v1 --out dataset_audit_2026-10-03-eval-test-v3-v1` `python tools/eval_test_audit.py --base data/v2 --out dataset_audit_2026-10-03-eval-test-v3-v2` 项目自带预检（只读）： `python tools/eval_test_prep.py check --eval data/v1/eval --test data/v1/test --train-dir data/v1/raw` → exit 0 契约依据： `DATASET_SCHEMA.md`、`EVAL_TEST_PREP.md`；证据：两个输出目录的 `issues.jsonl` / `summary.json` / `record_status.*` / `file_hashes.*` 历史轮次：第一轮 `dataset_audit_2026-10-03-eval-test/`（NOT READY, hard 3）、第二轮 `…-v2/`（CONDITIONAL PASS, hard 0）

---

0. 结论摘要与裁定

本轮出现两个候选版本，**分别检测**：

维度	v1（已冻结 19:25，不可变）	v2（22:09 新候选，待用户批准切换）
入口	`data/v1/{eval,test}/dataset_{eval,test}.jsonl`	`data/v2/{eval,test}/dataset_{eval,test}.jsonl`
记录数	300 + 150 = **450**	300 + 150 = **450**
逐条状态	rejected 0 / quarantine 450 / clean 0	rejected 0 / quarantine 450 / clean 0
hard	**0**	**0**
quarantine	**1353**	**904**
info	833	855
隔离（精确/近重复）	0 / max 0.6667	0 / max 0.6667
冻结锁	2 个，绑定 `data/v1/manifest.json`（校验通过）	2 个，绑定 v2 子清单（校验通过）
行尾/哈希可复现	**已修**（全 LF）	**已修**（全 LF）
清单条目契约	**已修**（子清单仅登记 JSONL，split=eval/test）	子清单合规，但**无顶层清单**
元数据 tag 卫生	**未修**（450 条 `"- "` 前缀残留）	**已修**（0 条）
scene_spec	v1 通用场景（objects 1200 / steps 1500）	**逐解法重写**（objects 612 / steps 1212，同题 3 解法场景互异 100/100）

裁定

- **v1：复核通过，四项必清中三项已清**（W001 行尾/哈希、MF005+MF009 清单条目、D011 手稿状态）。`F011`（450 条 tag 前缀残留）未清，但 v1 已冻结不可变，**由 v2 取代**；`D012`（文档仍写"未冻结"）为仓库级待办。
- **v2：硬门禁全部通过，可作为替代候选**；切换引用前仍需：① **顶层 manifest 登记**（`MF011`）+ 用户批准切换；② `A008` 动画验证（0/450）；③ `P002` 许可证转正（450）；④ `D012` 文档状态更新（3）。

---

1. 范围、快照与只读保证

类别	v1	v2
入口 JSONL	`data/v1/eval/dataset_eval.jsonl` (465152)、`data/v1/test/dataset_test.jsonl` (201290)	`data/v2/eval/dataset_eval.jsonl` (432636)、`data/v2/test/dataset_test.jsonl` (200390)
镜像 JSON	`…/dataset_eval.json` (524255)、`…/dataset_test.json` (224609)	`…/dataset_eval.json` (483003)、`…/dataset_test.json` (223709)
子清单	`data/v1/{eval,test}/manifest.json` (563×2)	`data/v2/{eval,test}/manifest.json` (573×2)
顶层清单	`data/v1/manifest.json` (2573)、`manifest-train.json` (2105)	**不存在**（MF011）
冻结锁	`data/{eval,test}-v1.lock.json`	`data/{eval,test}-v2.lock.json`
来源手稿（共用）	`dataset-eval.md` (205335)、`data-test.md` (118713)	同左
训练参考池	`data/v1/raw/dataset_{calc,geom,linalg,prob}.jsonl`（63 条，已 LF）	同左

- 快照时间：v1 运行 `2026-10-03T14:14:18Z`、v2 运行 `2026-10-03T14:14:19Z`（= 北京时间 22:14）；两个输出目录在运行后立即复核，受检文件哈希无变化。
- 只读保证：未修改任何数据、文档、清单或锁；未自动改 ID/公式；未启动训练、未下载模型、未生成动画。

---

2. 原始文件哈希（SHA256，本轮快照）

文件	字节	SHA256（前 12 位）
`data/v1/eval/dataset_eval.jsonl`	465152	`9e5b7355606d`
`data/v1/test/dataset_test.jsonl`	201290	`e1ba1eb49dd7`
`data/v1/eval/manifest.json` / `test/manifest.json`	563 / 563	`81a3e052ab06` / `1a15e8ca525b`
`data/eval-v1.lock.json` / `test-v1.lock.json`	469 / 469	`597f5f5b0f4b` / `01767d21555d`
`data/v2/eval/dataset_eval.jsonl`	432636	`8ff7044a0c48`
`data/v2/test/dataset_test.jsonl`	200390	`d4de0bb6a86f`
`data/v2/eval/manifest.json` / `test/manifest.json`	573 / 573	`a92d80727398` / `cd681f55f7d4`
`data/eval-v2.lock.json` / `test-v2.lock.json`	469 / 469	`e8d3fafc62fd` / `fa98d15f7db3`
`data/v1/raw/dataset_{calc,geom,linalg,prob}.jsonl`	32908 / 18138 / 31002 / 15462	见 `file_hashes.json`
`dataset-eval.md` / `data-test.md`	205335 / 118713	见 `file_hashes.json`

> 完整清单：v1 运行 19 个文件、v2 运行 17 个文件（v2 无顶层清单/无 v2 README）。见各自 `file_hashes.json`。

---

3. 上一轮（第二轮）四项建议必清的验收

上一轮项	本轮状态	证据
`W001` 记录哈希绑定 CRLF 而 `.gitattributes` 声明 `eol=lf`	**已修复**	提交 `a8f5071`「全量数据/清单/锁 LF 落盘 + 索引重规范化，两个 manifest 哈希按 LF 字节重算」；本轮实测：raw JSONL、v1/v2 JSONL、各级 manifest、锁**CRLF 计数全为 0**；fresh clone 复现见提交 `738d175`
`MF005` split 语义冲突（子清单标 `raw`）	**已修复**	`data/v1/{eval,test}/manifest.json` 现只登记 JSONL 且 `split=eval` / `test`
`MF009` 子清单把 `.json` 数组容器登记为数据条目	**已修复**	子清单条目从 3 条（含 `.json` 与 README）降为 1 条（仅 JSONL）；`M002` 仅剩"镜像"info
`F011` efficiency_tags 残留 `"- "` 前缀	**v1 未清 / v2 已清**	v1：450 条仍带前缀（数据冻结不可变）；v2：0 条（提交 `c599006` 修生成器、`4fe0152` 清理数据）
`D011` / `D012` 文档仍写"未冻结"	**部分修复**	`dataset-eval.md` / `data-test.md` 已去除"未冻结/草稿"字样；`EVAL_TEST_PREP.md`（6 处）与 `data/v1/{eval,test}/README.md`（标题）仍写"未冻结" → 本轮 `D012` ×3

---

4. v2 候选专项核验（Lead 独立复核）

4.1 v1 → v2 差异范围（逐字段比对 450 条）

池	记录数	差异字段命中
eval	300	`scene_spec` 300、`efficiency_tags` 300、`solution` **1**
test	150	`scene_spec` 150、`efficiency_tags` 150

→ v2 是**纯 scene_spec/元数据修订**（外加 1 条解法补全）；`id`、`problem`、`answer`、`category`、`source`、`license` 与 v1 逐条相同，**未引入新题目**，故隔离结论与 v1 一致。

4.2 逐解法 scene_spec（用户批准的 v2 核心改动）

- eval：100 个 problem_id、每组 3 个解法，**scene_spec 完全相同的组数 = 0**；首步文本完全相同的组数 = 0 → "逐解法场景"落实（`G003` info 通过）。
- 规模：eval objects 总计 **612**（每条 1–3）、steps 总计 **1212**（每条 3–5）；test objects 303 / steps 603。相比 v1（1200/1500）明显精简，符合"解法专属动画要点"的定位。
- 无空 objects/steps；450/450 均含两列表。

4.3 v2 对既有内容问题的处理

- `eval-linalg-023-s3`（上一轮内容评审 A 级关联项）已改为**自包含**：先给出实数域分解的两种形式，再用平方差恒等式连接并证明，`Lead 复核` 式子正确（$(x^2+1)^2-(\sqrt2x)^2=x^4+1$）。
- 上一轮 5 条 A 级（`test-prob-002`、`eval-calc-006`、`eval-linalg-023`、`test-linalg-021`、`test-x-011`）在 v2 中仍保持已修正状态（v2 未改动 problem/solution/answer，除上述 1 条）。

4.4 仍需补齐（v2）

项	说明
`MF011`	v2 只有子清单+锁，**无顶层** **`data/v2/manifest.json`** → 切换引用时需顶层登记，把 train/eval/test 绑到同一份清单并重冻
`A008` ×450	动画仍未验证：v2 同样无 `code` / `render_status` / `code_sha256`，scene_spec 仍是设计稿
`P002` ×450	`license=Internal-Research-Use-Only`（仅内部研究、不公开分发），训练/公开前须转正
`D012` ×3	`EVAL_TEST_PREP.md` 与 `data/v1/{eval,test}/README.md` 仍写"未冻结"

---

5. 硬门禁逐项结果（v1 / v2）

#	门禁	v1	v2
G1	JSONL 结构（解析/空行/BOM/重复键）	通过	通过
G2	必需字段/类型/未知字段	通过	通过
G3	身份唯一性（eval 300 + test 150，跨池无交集）	通过	通过
G4	同题多解组约束（100 组×3 解、题干一致、method 唯一）	通过	通过
G5	answer 可判分性	通过	通过
G6	LaTeX（公式内 CJK/全角/`$`/括号）	通过（0 硬性）	通过（0 硬性）
G7	scene_spec 结构	通过	通过
G8	镜像 `.json` ↔ JSONL 一致	通过（450/450）	通过（450/450）
G9	与 train 隔离	通过（精确 0；max 0.5915）	通过（同左）
G10	eval ↔ test 隔离	通过（精确 0；max **0.6667**；≥0.7 对数 0）	通过（同左）
G11	manifest 登记	通过（顶层+子清单）	**子清单通过，顶层缺失（MF011）**
G12	冻结锁校验（结构/条目哈希/manifest 绑定）	通过	通过
G13	元数据完备性	通过（513/513 齐全）	通过
G14	元数据卫生（tag 前缀）	**不通过**（F011×450）	通过
G15	行尾/哈希可复现	**通过**	通过
G16	文档状态一致	不通过（D012×3）	不通过（D012×3）
G17	动画验证	不通过（0/450）	不通过（0/450）

#	门禁	v1	v2
G18	许可证	不通过（内部研究）	不通过（内部研究）

---

6. 隔离检测

池对	精确重叠	最大 5-gram Jaccard（set）	≥0.7 对数
train ↔ eval	0	0.5915（`linalg-067` vs `eval-linalg-007-s1`）	0
train ↔ test	0	0.3895（`linalg-067` vs `test-linalg-021`）	0
eval ↔ test	0	0.6667（`eval-calc-023-s1` vs `test-calc-013`）	0

- v1 与 v2 的题目文本完全相同，故两张表的数值一致。
- 边界对（0.6667）经 Lead 复核为**结构性相似**（共用 LaTeX 脚手架；一题"证明 Σ1/n² 收敛"、一题"求 Σ1/(n(n+2)) 的和"，任务与级数均不同），非题面泄漏；阈值 0.7 仍标 UNCALIBRATED，建议纳入校准。
- **门禁盲区仍未关闭**：`tools/eval_test_prep.py check` 的 eval↔test 比较仍只用"核心正文哈希 + ID"，不做组间近重复（第三轮仍无变化）。

---

7. 逐条问题清单

7.1 硬伤：v1 0 条、v2 0 条

7.2 quarantine

代码	v1	v2	内容	处置建议
`P002`	450	450	`license=Internal-Research-Use-Only`	训练/公开前转正（用户级）
`A008`	450	450	动画未验证（无 code/render_status/code_sha256）	过 `render_gate` 后登记（用户级）
`F011`	**450**	0	efficiency_tags 残留 `"- "` 前缀	v2 已清；v1 不再改（被取代）
`D012`	3	3	`EVAL_TEST_PREP.md` + `data/v1/{eval,test}/README.md` 写"未冻结"	更新文档（仓库级）
`MF011`	0	**1**	v2 无顶层 manifest	批准切换后顶层登记并重冻
合计	**1353**	**904**		

7.3 info（v1 833 / v2 855）

代码	v1	v2	内容
`P003`	450	450	`source=self-authored`（如实）
`C007`	274	274	answer 与 solution 无文本重合（纯文字结论，正常）
`L007`	86	100	双上下标（`x_1^2` 类，合法）

代码	v1	v2	内容
`L006`	7	11	`\leftarrow` 被 `\left` 规则误报（复核为误报）
`L009`	3	7	`\frac32` / `\dfrac12` 单 token 参数（合法 TeX，复核为误报）
`X002`	3	3	三对池最大近重复（0.5915 / 0.3895 / 0.6667）
`M002`	2	2	`.json` 仅作镜像（入场工具只选 `*.jsonl`）
`LK007` / `LK008`	2/1	2/1	本基目录锁校验通过 / 其他基目录锁未校验
`G002` / `G003`	1/1	1/1	多解组 {3:100} / 场景互异性通过
`C008`	1	1	`A^2=A` 恒等演示（复核为误报）
`MF008`	1	1	train 标签为"用户拍板 provisional"（如实）
`R001`	1	1	既有内容评审 64 条（A5/B31/C28）纳入交叉核对

---

8. 汇总统计

项	v1	v2
eval / test 记录	300 / 150	300 / 150
唯一身份	300 / 150	300 / 150
题目数	100（每组 3 解）/ 150	100（每组 3 解）/ 150
子类数	41 / 144	41 / 144
objects / steps	1200 / 1500（eval）、303 / 603（test）	**612 / 1212**（eval）、303 / 603（test）
method 数	263	263
状态	rejected 0 / quarantine 450 / clean 0	rejected 0 / quarantine 450 / clean 0
动画验证	0/450	0/450

- 板块：eval（高代 105 / 数分 90 / 几何 60 / 概率 45，按解法计）；test（数分 45 / 高代 40 / 几何 25 / 概率 25 / 跨学科 15）。

---

9. 裁定与建议

1. **v1 完成使命**：第二轮所列 W001/MF005/MF009/D011 均已修复并复核；剩下的 F011 属数据内容问题，v1 已冻结不可变，**不再回改**（保留其历史版本价值）。文档 `D012` 建议在最终切换时一并更新。
2. **v2 可进入"批准切换"流程**：结构与字段、身份、多解组、LaTeX、镜像、隔离、冻结锁、元数据卫生全部通过（hard 0）。切换前需完成：
   - ① **顶层 manifest 登记**：在 `data/v2/manifest.json` 里把 train（raw 63）+ eval + test 绑成同一份清单，重建双锁（当前锁只绑子清单）；
   - ② **用户批准**引用切换（v2 notes 已注明"切换引用需用户批准"）；
   - ③ 动画验证（`A008` 450）：过 `render_gate` → 登记 `code` / `render_status=verified` / `code_sha256`；
   - ④ 许可证转正（`P002` 450）。
3. **门禁能力建议**：给 `eval_test_prep.py check` 补 eval↔test 近重复比较；并对 0.7 阈值做一次校准（0.6667 边界对可作校准样本）。

4. **不建议**在完成 ①–④ 前把 v2（或 v1）当作正式训练/评测数据引用；`manifest-train.json` 的 `split=train` 仍为 provisional（notes 如实注明未验收）。

---

10. 产物清单

路径	内容
`dataset_audit_2026-10-03-eval-test-v3/AUDIT_REPORT.md` / `.pdf`	本报告（合并 v1 复核 + v2 候选裁定）
`dataset_audit_2026-10-03-eval-test-v3-v1/`	v1 检测输出：`issues.jsonl` (2186)、`summary.json`、`record_status.*`、`file_hashes.*`
`dataset_audit_2026-10-03-eval-test-v3-v2/`	v2 检测输出：`issues.jsonl` (1759)、`summary.json`、`record_status.*`、`file_hashes.*`
`tools/eval_test_audit.py`	只读检测工具（支持 `--base`，可复现）

声明：本轮为只读预跑检测，未修改任何数据、文档、清单或锁；未自动改 ID/公式；未启动训练、未下载模型、未生成动画。